



SENA - Servicio Nacional de Aprendizaje

Análisis Exploratorio de Datos en Python

Evidencia AA3-EV02: Informe en el que se identifiquen las variables y los componentes estadísticos a partir de una situación planteada

Presentado por:

Liliana Andrea Díaz Sippli

Presentado a:

Instructor Luis Alberto Galicia Guerrero

Barranquilla, Colombia

18/11/2025

Introducción

El presente análisis exploratorio de datos (EDA) tiene como objetivo comprender cómo influyen las características de un inmueble en la variación de su precio. Para ello, se estudiaron variables categóricas como Ciudad, Departamento, Estrato, Tipo de Inmueble y Detalle de Disponibilidad, combinadas con el valor del Precio. El EDA incluye análisis univariados, bivariados y multivariados con técnicas como histogramas y boxplots con escala logarítmica además de comparaciones entre múltiples categorías.

Análisis Exploratorio de Datos en Python de inmuebles para venta

El análisis inicia con la importación de las librerías necesarias para el tratamiento y visualización de datos. Posteriormente, se realiza la carga del dataset original, seguido de una revisión inicial de su estructura, tipos de datos y contenido, lo que permite verificar que la información se encuentra en el estado adecuado para continuar con el proceso de exploración.

```
import pandas as pd
import matplotlib.pyplot as plt
import matplotlib.ticker as mtick
import seaborn as sns
import numpy as np
```

```
df = pd.read_csv('Data_Caso_Propuesto.csv')
pd.set_option('display.float_format', '{:.2f}'.format)
df
```

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 463 entries, 0 to 462
Data columns (total 12 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Codigo                 463 non-null   int64
1   Ciudad                 463 non-null   object
2   Departamento           463 non-null   object
3   Barrio                 40 non-null    object
4   Direccion              463 non-null   object
5   Area Terreno           463 non-null   float64
6   Area Construida        463 non-null   float64
7   Detalle Disponibilidad 463 non-null   object
8   Estrato                463 non-null   object
9   Precio                463 non-null   float64
10  Tipo de Inmueble        463 non-null   object
11  Datos Adicionales       118 non-null   object
dtypes: float64(3), int64(1), object(8)
memory usage: 43.5+ KB
```

Ahora nos enfocamos en verificar si hay nulos y duplicados; de estos últimos no hay, pero de los nulos hay muchos, lo que impide que se puedan eliminar ya que el dataset quedaría prácticamente sin nada de registros; además, los nulos se encuentran en columnas que no son necesarias para este análisis por lo que se eliminan las columnas:

```
df.isnull().sum()
```

```
Codigo                0
Ciudad                0
Departamento         0
Barrio                423
Direccion             0
Area Terreno          0
Area Construida       0
Detalle Disponibilidad 0
Estrato               0
Precio               0
Tipo de Inmueble      0
Datos Adicionales     345
dtype: int64
```

```
df.duplicated().sum()
```

```
0
```

```
df.drop(columns=['Barrio', 'Direccion', 'Datos Adicionales'], inplace=True)
```

Verificamos datos estadísticos del dataset:

```
df.describe()
```

	Codigo	Area Terreno	Area Construida	Precio
count	463.00	463.00	463.00	463.00
mean	18003.15	15152.04	87.52	667203190.31
std	1992.19	182710.10	1137.47	3272992027.69
min	2575.00	0.00	0.00	4650000.00
25%	18184.50	0.00	0.00	12305000.00
50%	18332.00	0.00	0.00	15870000.00
75%	18539.50	0.00	0.00	137995500.00
max	19344.00	3217197.00	22724.00	45233789820.00

```
df.describe(include='object')
```

	Ciudad	Departamento	Detalle Disponibilidad	Estrato	Tipo de Inmueble
count	463	463	463	463	463
unique	43	14	6	9	19
top	VILLAVICENCIO	META	COMERCIALIZABLE	COMERCIAL	LOCAL
freq	290	292	289	307	305

Ahora sí, pasamos al EDA: la pregunta planteada para este es: **¿Cómo influyen las características de un inmueble en su precio?**


Para resolverla, este análisis se divide en Univariado, Bivariado y Multivariado.

Análisis Univariado: comenzamos analizando el Precio:

Al realizar un histograma de Precio, se observa que no luce adecuadamente, por lo que, investigando más sobre esto, se concluye que la causa es la presencia de muchos valores atípicos en el dataset, así que estos proceden a eliminarse mediante el método IQR, surgiendo de esto, un nuevo dataset:

```
sns.histplot(df.Precio, color='darkgreen', bins=10, kde=True)
plt.title('Histograma Precio')
plt.xlabel('Precio')
plt.ylabel('Cantidad')
```

```
Text(0, 0.5, 'Cantidad')
```



SIN OUTLIERS

```
Q1 = df['Precio'].quantile(0.25)
Q3 = df['Precio'].quantile(0.75)
IQR = Q3 - Q1

limite_superior = Q3 + 1.5 * IQR
limite_inferior = Q1 - 1.5 * IQR

df_sin_outliers = df[(df['Precio'] >= limite_inferior) & (df['Precio'] <= limite_superior)]

print(f"Datos originales: {len(df)} filas")
print(f"Datos después de la limpieza IQR: {len(df_sin_outliers)} filas")


Datos originales: 463 filas
Datos después de la limpieza IQR: 377 filas
```

Ahora, se procede con el análisis usando el nuevo dataset, pero al realizar nuevamente el histograma, se observa que este presenta sesgo a la derecha (lo cual sucede porque unos pocos registros con valores grandes hacen que la cola del histograma se extienda hacia la derecha), por lo que, para su mejor visualización, se debe aplicar transformación logarítmica a la variable Precio, por lo que se crea una nueva columna con esta condición:

Precio


```
plt.figure(figsize=(8, 6))
sns.histplot(df_sin_outliers.Precio, color='lightseagreen', bins=5, kde=True)
plt.ticklabel_format(style='plain', axis='x')
plt.gca().xaxis.set_major_formatter(mtick.FuncFormatter(lambda x, _ : f'{x:,0f}'))
plt.title('Histograma Precio')
plt.xlabel('Precio')
plt.ylabel('Cantidad')
```

```
Text(0, 0.5, 'Cantidad')
```





```
df_sin_outliers["Precio_log"] = np.log(df_sin_outliers["Precio"])
df_sin_outliers
```

Ahora, ya se puede apreciar mejor el histograma y se observa un pico entre 16 y 17, es decir que la mayoría de los precios están concentrados en 8.886.111 y 24.154.953, valores que se obtienen mediante la inversa del logaritmo e^{16} y e^{17} .



Lo siguiente es analizar las variables categóricas (algunas se acortaron a Top 10 ya que tienen varias categorías):






Del análisis univariado, las conclusiones son las siguientes:

Variable	Conclusión
Precio (<i>Precio_log</i>)	Oscilan entre 8.886.111 y 24.154.953 aproximadamente.
Departamento	Meta es quien tiene más registros.
Ciudad	Villavicencio tiene más registros.
Tipo de Inmueble	El tipo 'Local' es el ganador.
Estrato	El estrato 'Comercial' es el ganador.
Detalle Disponibilidad	Los inmuebles 'Comercializables' son los ganadores.


Análisis Bivariado: se compara *Precio_log* con cada variable categórica. En el notebook se encuentran los gráficos con *Precio* y también con *Precio_log*



```
plt.figure(figsize=(10,6))
sns.boxplot(data=df_sin_outliers, x='Estrato', y='Precio_log', color='darkviolet')
plt.xticks(rotation=45)
plt.ticklabel_format(style='plain', axis='y')
plt.gca().yaxis.set_major_formatter(mtick.FuncFormatter(lambda x, _: f'{x:,0f}'))
plt.title("Precio por Estrato Log")
plt.show()
```



```
plt.figure(figsize=(10,6))
sns.boxplot(data=df_sin_outliers, x='Detalle Disponibilidad', y='Precio_log', color='mediumslateblue')
plt.xticks(rotation=45)
plt.ticklabel_format(style='plain', axis='y')
plt.gca().yaxis.set_major_formatter(mtick.FuncFormatter(lambda x, _: f'{x:,0f}'))
plt.title("Precio por Detalle Disponibilidad Log")
plt.show()
```



Del análisis bivariado, se obtiene que:

Precio_log por Ciudad

Medellín, Tarazá, Barranquilla y Manizales tienen los inmuebles más costosos; Cali y Pácora tienen los menos costosos. En las demás ciudades se observa cierta variabilidad en los precios.

Precio_log por Tipo de Inmueble

Casi todos los tipos de inmuebles tienen precios altos (destacando oficina, casa y finca) menos Depósito y Lote Agrícola.

Precio_log por Estrato


Los estratos con precio más alto son Cinco, Rural, Seis, Cuatro; mientras que en Uno y Comercial hay inmuebles más económicos.

Precio_log por Detalle Disponibilidad

Los inmuebles Comercializables con Venta Anticipada y Comercializable Terceros son más costosos.

Análisis Multivariado:

Se comparan las variables numéricas entre sí mediante el Mapa de Calor (exceptuando el Código). La correlación de Precio con las variables Area Terreno y Area Construida es muy baja ya que la mayoría de los registros de ambas variables son 0. Es por esto que dichas variables no se tuvieron en cuenta para este EDA:




Area Terreno	Area Construida
3,786,133	176,500
33,799,500	0
10,962,744	0
414,800	0
0	0
0	0
0	0
0	0
0	0
0	0
0	0
0	0
0	9,147
0	0
0	0
0	0

Relación de Tipo de Inmueble, Precio y Estrato

```

sns.relplot(x='Tipo de Inmueble', y='Precio_log', hue='Estrato', data=df_sin_outliers, aspect = 3)
plt.xticks(rotation=45)
plt.ticklabel_format(style='plain', axis='y')
plt.gca().yaxis.set_major_formatter(mtick.FuncFormatter(lambda x, _: f'{x:,.0f}'))

```




Los inmuebles más costosos son: oficinas en estratos cinco y seis; casas en estrato uno, (en el boxplot de *Precio_log* por *Estrato* se observan algunos valores atípicos) también fincas, lotes y lotes con construcción en estrato rural; lotes de vivienda y locales en estrato cuatro y apartamentos en estrato tres.

Relación de Tipo de Inmueble, Precio y Detalle Disponibilidad

```

sns.relplot(x='Tipo de Inmueble', y='Precio_log', hue='Detalle Disponibilidad', data=df_sin_outliers, aspect = 3)
plt.xticks(rotation=45)
plt.ticklabel_format(style='plain', axis='y')
plt.gca().yaxis.set_major_formatter(mtick.FuncFormatter(lambda x, _: f'{x:,.0f}'))

```



Los inmuebles más costosos son las oficinas comercializables con venta anticipada; las casas, fincas, lotes con construcción comercializable terceros y los lotes vivienda comercializables.

Conclusiones

El análisis realizado demuestra que las características del inmueble influyen de manera significativa en su precio. Variables como el estrato, la ciudad y el tipo de inmueble presentan una relación directa con las variaciones del valor, siendo los factores que más explican las diferencias observadas. Los estratos más altos y zonas rurales muestran precios mayores, mientras que ciudades como Medellín, Barranquilla y Tarazá concentran los valores más elevados, reflejando mercados más costosos y, en algunos casos, menos dispersos. En cuanto al tipo de inmueble, las casas, fincas y oficinas tienen precios elevados mientras que los distintos tipos de lote exhiben mayor variabilidad de precios. En conjunto, los resultados evidencian que la ubicación y el nivel socioeconómico del área son los determinantes más importantes del precio, complementados por las características estructurales del inmueble. Esto permite concluir que el precio final es el resultado de la interacción entre el contexto geográfico y las particularidades del inmueble.